## Matrices\_Moran\_Geary\_Hotspots.R

#### **ASUS**

#### 2025-10-15

```
library(spdep)
## Cargando paquete requerido: spData
## To access larger datasets in this package, install the spDataLarge
## package with: 'install.packages('spDataLarge',
## repos='https://nowosad.github.io/drat/', type='source')'
## Cargando paquete requerido: sf
## Linking to GEOS 3.13.1, GDAL 3.11.0, PROJ 9.6.0; sf_use_s2() is TRUE
library(sf)
library(ggplot2)
library(viridis)
## Cargando paquete requerido: viridisLite
# 1. DATOS ESPACIALES DE EJEMPLO
set.seed(123)
# Crear una cuadrícula de 10x10 polígonos
n_rows <- 10
n_cols <- 10
cell_size <- 1
# Generar coordenadas de los centroides
coords <- expand.grid(x = 1:n_cols, y = 1:n_rows)</pre>
# Crear polígonos (cuadrados)
polys <- list()</pre>
for(i in 1:nrow(coords)) {
 x <- coords$x[i]
 y <- coords$y[i]
 poly_coords <- matrix(c(</pre>
```

```
x - 0.5, y - 0.5,
    x + 0.5, y - 0.5,
   x + 0.5, y + 0.5,
   x - 0.5, y + 0.5,
   x - 0.5, y - 0.5
  ), ncol = 2, byrow = TRUE)
 polys[[i]] <- st_polygon(list(poly_coords))</pre>
# Crear objeto sf
spatial_data <- st_sf(</pre>
 id = 1:nrow(coords),
 geometry = st_sfc(polys),
 crs = NA
# Agregar variable de interés con autocorrelación espacial
# Crear clusters de valores altos y bajos
spatial_data$valor <- rnorm(nrow(spatial_data), mean = 50, sd = 10)</pre>
# Crear hotspot en la esquina superior derecha
hotspot_ids <- which(coords$x >= 7 & coords$y >= 7)
spatial_data$valor[hotspot_ids] <- spatial_data$valor[hotspot_ids] + 30</pre>
# Crear coldspot en la esquina inferior izquierda
coldspot_ids <- which(coords$x <= 4 & coords$y <= 4)</pre>
spatial_data$valor[coldspot_ids] <- spatial_data$valor[coldspot_ids] - 20</pre>
# 2. MATRICES DE PESOS ESPACIALES
cat("\n=== MATRICES DE PESOS ESPACIALES ===\n")
## === MATRICES DE PESOS ESPACIALES ===
# 2.1 Matriz de vecindad por contigüidad (Queen)
nb_queen <- poly2nb(spatial_data, queen = TRUE)</pre>
cat("\nVecinos por contigüidad Queen (8 vecinos):\n")
##
## Vecinos por contigüidad Queen (8 vecinos):
print(summary(nb_queen))
## Neighbour list object:
## Number of regions: 100
## Number of nonzero links: 684
## Percentage nonzero weights: 6.84
## Average number of links: 6.84
```

```
## Link number distribution:
##
## 3 5 8
## 4 32 64
## 4 least connected regions:
## 1 10 91 100 with 3 links
## 64 most connected regions:
## 12 13 14 15 16 17 18 19 22 23 24 25 26 27 28 29 32 33 34 35 36 37 38 39 42 43 44 45 46 47 48 49 52 5
# 2.2 Matriz de vecindad por contigüidad (Rook)
nb_rook <- poly2nb(spatial_data, queen = FALSE)</pre>
cat("\nVecinos por contigüidad Rook (4 vecinos):\n")
##
## Vecinos por contigüidad Rook (4 vecinos):
print(summary(nb_rook))
## Neighbour list object:
## Number of regions: 100
## Number of nonzero links: 360
## Percentage nonzero weights: 3.6
## Average number of links: 3.6
## Link number distribution:
##
## 2 3 4
## 4 32 64
## 4 least connected regions:
## 1 10 91 100 with 2 links
## 64 most connected regions:
## 12 13 14 15 16 17 18 19 22 23 24 25 26 27 28 29 32 33 34 35 36 37 38 39 42 43 44 45 46 47 48 49 52 5
# 2.3 Convertir a matriz de pesos (row-standardized)
W_queen <- nb2listw(nb_queen, style = "W", zero.policy = TRUE)</pre>
W_rook <- nb2listw(nb_rook, style = "W", zero.policy = TRUE)</pre>
# 2.4 Matriz de pesos por distancia (k-vecinos más cercanos)
coords_centroids <- st_coordinates(st_centroid(spatial_data))</pre>
## Warning: st_centroid assumes attributes are constant over geometries
k < -4
nb_knn <- knn2nb(knearneigh(coords_centroids, k = k))</pre>
W_knn <- nb2listw(nb_knn, style = "W")
cat("\nVecinos por k-NN (k=4):\n")
## Vecinos por k-NN (k=4):
```

```
print(summary(nb_knn))
## Neighbour list object:
## Number of regions: 100
## Number of nonzero links: 400
## Percentage nonzero weights: 4
## Average number of links: 4
## Non-symmetric neighbours list
## Link number distribution:
##
##
## 100
## 100 least connected regions:
## 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 3
## 100 most connected regions:
## 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 3
# 3. ÍNDICE DE MORAN (AUTOCORRELACIÓN ESPACIAL GLOBAL)
# ------
cat("\n\n=== INDICE DE MORAN ===\n")
##
##
## === ÍNDICE DE MORAN ===
# Calcular el Índice de Moran I
moran_test <- moran.test(spatial_data$valor, W_queen)</pre>
cat("\nÍndice de Moran I:\n")
## Índice de Moran I:
print(moran_test)
##
## Moran I test under randomisation
##
## data: spatial_data$valor
## weights: W_queen
## Moran I statistic standard deviate = 11.306, p-value < 2.2e-16
## alternative hypothesis: greater
## sample estimates:
## Moran I statistic
                       Expectation
                                           Variance
                       -0.010101010
##
       0.593336420
                                        0.002848939
# Interpretación
cat("\nInterpretación del Índice de Moran:\n")
```

```
##
## Interpretación del Índice de Moran:
cat(sprintf("Moran's I = %.4f\n", moran_test$estimate[1]))
## Moran's I = 0.5933
cat(sprintf("p-value = %.4f\n", moran_test$p.value))
## p-value = 0.0000
if(moran_test$p.value < 0.05) {</pre>
 if(moran_test$estimate[1] > 0) {
   cat("Conclusión: Existe autocorrelación espacial POSITIVA significativa\n")
   cat("(valores similares tienden a agruparse espacialmente)\n")
 } else {
   cat("Conclusión: Existe autocorrelación espacial NEGATIVA significativa\n")
   cat("(valores diferentes tienden a estar juntos)\n")
 }
} else {
 cat("Conclusión: No hay evidencia de autocorrelación espacial\n")
## Conclusión: Existe autocorrelación espacial POSITIVA significativa
## (valores similares tienden a agruparse espacialmente)
# Test de permutación de Monte Carlo
moran_mc <- moran.mc(spatial_data$valor, W_queen, nsim = 999)</pre>
cat("\n\nTest de Monte Carlo (999 permutaciones):\n")
##
##
## Test de Monte Carlo (999 permutaciones):
print(moran_mc)
##
## Monte-Carlo simulation of Moran I
## data: spatial_data$valor
## weights: W_queen
## number of simulations + 1: 1000
## statistic = 0.59334, observed rank = 1000, p-value = 0.001
## alternative hypothesis: greater
# ------
# 4. ÍNDICE DE GEARY (AUTOCORRELACIÓN ESPACIAL GLOBAL)
cat("\n\n=== INDICE DE GEARY ===\n")
```

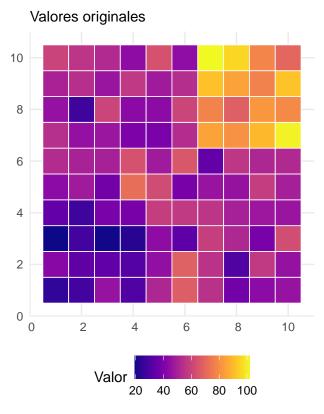
```
##
##
## === ÍNDICE DE GEARY ===
# Calcular el Índice de Geary C
geary_test <- geary.test(spatial_data$valor, W_queen)</pre>
cat("\nÍndice de Geary C:\n")
##
## Índice de Geary C:
print(geary_test)
## Geary C test under randomisation
## data: spatial_data$valor
## weights: W_queen
## Geary C statistic standard deviate = 10.954, p-value < 2.2e-16
## alternative hypothesis: Expectation greater than statistic
## sample estimates:
## Geary C statistic
                           Expectation
                                                 Variance
         0.395053834
                           1.000000000
                                              0.003050118
# Interpretación
cat("\nInterpretación del Índice de Geary:\n")
##
## Interpretación del Índice de Geary:
cat(sprintf("Geary's C = %.4f\n", geary_test$estimate[1]))
## Geary's C = 0.3951
cat(sprintf("p-value = %.4f\n", geary_test$p.value))
## p-value = 0.0000
cat("\nNota: Geary's C varía de 0 a 2+\n")
## Nota: Geary's C varía de 0 a 2+
cat("C < 1: autocorrelación positiva\n")</pre>
## C < 1: autocorrelación positiva
```

```
cat("C = 1: aleatoriedad espacial\n")
## C = 1: aleatoriedad espacial
cat("C > 1: autocorrelación negativa\n")
## C > 1: autocorrelación negativa
# Test de permutación de Monte Carlo
geary_mc <- geary.mc(spatial_data$valor, W_queen, nsim = 999)</pre>
cat("\n\nTest de Monte Carlo (999 permutaciones):\n")
##
##
## Test de Monte Carlo (999 permutaciones):
print(geary_mc)
##
## Monte-Carlo simulation of Geary C
##
## data: spatial_data$valor
## weights: W_queen
## number of simulations + 1: 1000
##
## statistic = 0.39505, observed rank = 1, p-value = 0.001
## alternative hypothesis: greater
# ------
# 5. ANÁLISIS DE HOTSPOTS (LISA - Local Indicators of Spatial Association)
# ______
cat("\n\n=== ANÁLISIS DE HOTSPOTS (LISA) ===\n")
##
## === ANÁLISIS DE HOTSPOTS (LISA) ===
# Calcular indices de Moran locales
local_moran <- localmoran(spatial_data$valor, W_queen)</pre>
# Agregar resultados al dataset
spatial_data$local_I <- local_moran[, 1] # Indice local</pre>
spatial_data$local_pval <- local_moran[, 5] # p-valor</pre>
# Estandarizar valores para clasificación
spatial_data$valor_std <- scale(spatial_data$valor)</pre>
spatial_data$lag_valor_std <- lag.listw(W_queen, spatial_data$valor_std)</pre>
# Clasificar en categorías LISA
```

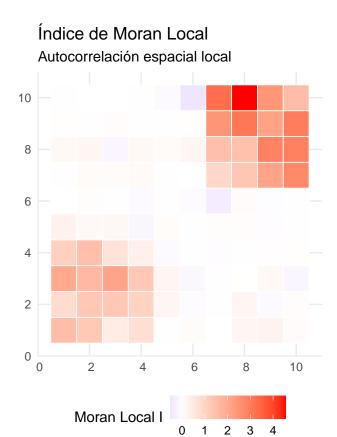
```
spatial_data$lisa_cat <- "No significativo"</pre>
sig_level <- 0.05
# High-High (Hotspots)
spatial_data$lisa_cat[spatial_data$valor_std > 0 &
                      spatial_data$lag_valor_std > 0 &
                      spatial_data$local_pval < sig_level] <- "High-High (Hotspot)"</pre>
# Low-Low (Coldspots)
spatial_data$lisa_cat[spatial_data$valor_std < 0 &</pre>
                      spatial_data$lag_valor_std < 0 &</pre>
                      spatial_data$local_pval < sig_level] <- "Low-Low (Coldspot)"</pre>
# High-Low (Outliers)
spatial_data$lisa_cat[spatial_data$valor_std > 0 &
                      spatial_data$lag_valor_std < 0 &</pre>
                       spatial_data$local_pval < sig_level] <- "High-Low (Outlier)"
# Low-High (Outliers)
spatial_data$lisa_cat[spatial_data$valor_std < 0 &</pre>
                      spatial_data$lag_valor_std > 0 &
                      spatial_data$local_pval < sig_level] <- "Low-High (Outlier)"</pre>
# Resumen de clusters
cat("\nDistribución de clusters LISA:\n")
## Distribución de clusters LISA:
print(table(spatial_data$lisa_cat))
##
## High-High (Hotspot) Low-High (Outlier) Low-Low (Coldspot)
                                                              No significativo
# 6. VISUALIZACIONES
# -----
# Gráfico 1: Variable original
p1 <- ggplot(spatial_data) +
 geom_sf(aes(fill = valor), color = "white", size = 0.3) +
 scale_fill_viridis(option = "plasma", name = "Valor") +
 labs(title = "Distribución de la Variable",
      subtitle = "Valores originales") +
 theme_minimal() +
 theme(legend.position = "bottom")
# Gráfico 2: Índice de Moran Local
p2 <- ggplot(spatial_data) +</pre>
 geom_sf(aes(fill = local_I), color = "white", size = 0.3) +
 scale_fill_gradient2(low = "blue", mid = "white", high = "red",
```

```
midpoint = 0, name = "Moran Local I") +
  labs(title = "Índice de Moran Local",
       subtitle = "Autocorrelación espacial local") +
  theme minimal() +
  theme(legend.position = "bottom")
# Gráfico 3: Significancia estadística
spatial_data$significativo <- ifelse(spatial_data$local_pval < 0.05,</pre>
                                      "Significativo (p<0.05)",
                                      "No significativo")
p3 <- ggplot(spatial_data) +
  geom_sf(aes(fill = significativo), color = "white", size = 0.3) +
  scale_fill_manual(values = c("Significativo (p<0.05)" = "red",</pre>
                                "No significativo" = "gray90"),
                    name = "") +
  labs(title = "Significancia Estadística",
       subtitle = "Áreas con autocorrelación significativa") +
  theme_minimal() +
  theme(legend.position = "bottom")
# Gráfico 4: Clusters LISA (Hotspots/Coldspots)
lisa_colors <- c("High-High (Hotspot)" = "#d7191c",</pre>
                 "Low-Low (Coldspot)" = "#2b83ba",
                 "High-Low (Outlier)" = "#fdae61",
                 "Low-High (Outlier)" = "#abd9e9",
                 "No significativo" = "gray90")
p4 <- ggplot(spatial_data) +
  geom_sf(aes(fill = lisa_cat), color = "white", size = 0.3) +
  scale_fill_manual(values = lisa_colors, name = "Categoría LISA") +
  labs(title = "Clusters LISA: Hotspots y Coldspots",
       subtitle = "High-High = Hotspots, Low-Low = Coldspots") +
  theme_minimal() +
  theme(legend.position = "bottom")
# Mostrar gráficos
print(p1)
```

## Distribución de la Variable



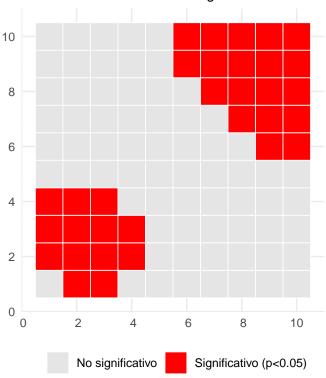
print(p2)



print(p3)

# Significancia Estadística

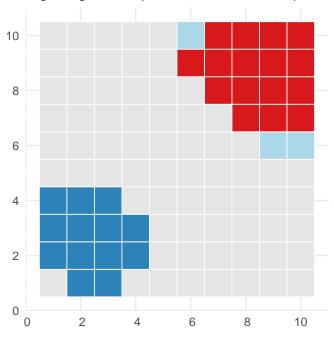
Áreas con autocorrelación significativa



print(p4)

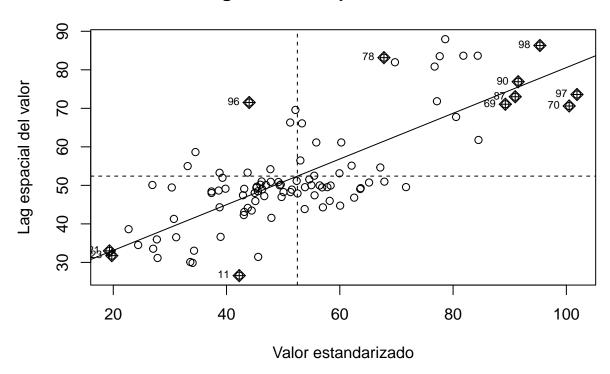
### Clusters LISA: Hotspots y Coldspots

High-High = Hotspots, Low-Low = Coldspots



```
Categoría LISA High-High (Hotspot) Low-High (Outlier) Low-Low (Coldspot) No significa
```

### Diagrama de Dispersión de Moran



print(head(resultados, 10))

```
## id valor moran_local pvalor categoria_lisa
## 1 1 24.39524 1.586413079 0.071070361 No significativo
## 2 2 27.69823 1.286903583 0.030986851 Low-Low (Coldspot)
## 3 3 45.58708 0.457411405 0.007078416 Low-Low (Coldspot)
```

## Primeras filas del resultado:

```
4 30.70508  0.767024101  0.142577720
                                            No significativo
## 5 5 51.29288 0.016145057 0.587654990 No significativo
## 6 6 67.15065 0.098055682 0.770777978 No significativo
     7 54.60916 -0.006390617 0.904138788 No significativo
## 8 8 37.34939 0.213485389 0.553171433 No significativo
## 9 9 43.13147 0.276416619 0.226304060 No significativo
## 10 10 45.54338 0.088032040 0.688901499 No significative
# Opcional: guardar resultados
# write.csv(resultados, "resultados_analisis_espacial.csv", row.names = FALSE)
# st_write(spatial_data, "datos_espaciales.shp")
cat("\n\n=== ANÁLISIS COMPLETADO ===\n")
##
##
## === ANÁLISIS COMPLETADO ===
cat("\nResumen de métricas globales:\n")
## Resumen de métricas globales:
cat(sprintf("- Índice de Moran I: %.4f (p = %.4f)\n",
           moran_test$estimate[1], moran_test$p.value))
## - Índice de Moran I: 0.5933 (p = 0.0000)
cat(sprintf("- Índice de Geary C: %.4f (p = %.4f)\n",
           geary_test$estimate[1], geary_test$p.value))
## - Índice de Geary C: 0.3951 (p = 0.0000)
cat(sprintf("- Hotspots detectados: %d\n",
           sum(spatial_data$lisa_cat == "High-High (Hotspot)")))
## - Hotspots detectados: 16
cat(sprintf("- Coldspots detectados: %d\n",
           sum(spatial_data$lisa_cat == "Low-Low (Coldspot)")))
## - Coldspots detectados: 13
```